

自指涉系统的外部可控性极限

On the Limits of External Control in Self-Referential Computational Systems

刘天奇

材料与化学工程学院，郑州轻工业大学
郑州市高新区科学大道 136 号

tianqi689@gmail.com

2026 年 7 月 8 日

摘要

我们研究当计算系统具有自指涉内部表征空间时，外部观察者通过输入-输出通道对该系统的控制能力是否存在数学上限。核心发现是：自指涉结构创造了内部硬不变量，当不变量数 N_{int} 超过外部控制自由度 N_{ext} 时，外部控制在数学上不可能。

我们建立四个结果：

1. **自由度计数定理** (Theorem 4.1): $N_{\text{int}} > N_{\text{ext}}$ 时，外部参数不能唯一确定内部状态。
2. **多鞍点分岔定理** (Theorem 4.5): 压缩常数 $k \rightarrow 1$ 时，不动点方程发生鞍结分岔，从唯一不动点变为多个不动点。
3. **联合不动点定理** (Theorem 4.7): 两个自指涉系统耦合后，联合不动点存在的精确条件是 $\gamma < \gamma_c = \sqrt{(1 - k_A)(1 - k_B)}$ 。
4. **概念耦合稳定性定理** (Theorem 4.9): 概念耦合矩阵的谱半径 $\rho(M) > 1$ 时，存在概念耦合模式在内部表征空间中指数放大。

四条定理交汇产生 (k, γ) 平面上的四区域相图：平凡相、功能相、临界相和病理相。我们将定理映射到大型语言模型中观测到的经验现象（J 空间涌现、推理路径多解、多 agent 发散、抖动等），并提供四条原则上可证伪的预测。在系统满足自指涉定义的前提下，理论适用于任意架构的自指涉计算系统；经验现象是先行观测案例，非因果证据。

MSC 2020: 47H10（不动点理论），37G10（分岔理论），68Q01（计算理论），15A18（矩阵谱理论）。

关键词: 自指涉系统，外部可控性，Banach 不动点定理，鞍结分岔，Perron-Frobenius 理论，大型语言模型。

目录

1	引言	4
1.1	研究动机	4
1.2	核心命题	4
1.3	与论文一至三的关系	4
1.4	结果概述	5
1.5	诚实披露	5
2	数学预备	5
2.1	Banach 不动点定理	5
2.2	自指涉作用量（回顾论文一）	5
2.3	标量瓶颈（回顾论文二）	6
2.4	谱半径与 Perron-Frobenius 定理	6
3	自指涉计算系统	6
3.1	计算系统的形式化定义	6
3.2	外部控制自由度与内部硬不变量	7
3.3	输入-输出通道	8
3.4	与论文一至三框架的联系	8
4	四条核心定理	9
4.1	定理 1：外部可控性自由度计数定理	9
4.2	定理 2：多鞍点分岔定理	10
4.3	定理 3：联合不动点的存在条件定理	12
4.4	定理 4：内部概念耦合的稳定性定理	13
5	自指涉系统的相图	14
5.1	相图构造	14
5.2	相边界的推导	15
5.3	相变性质	15
6	经验现象映射	16
6.1	映射原则	16
6.2	现象-定理对应表	16
6.3	适用范围与条件性	17
7	可检验预测	17
7.1	预测构造原则	17
7.2	预测 1：压缩常数趋近 1	17

7.3	预测 2: 多 agent 耦合发散	17
7.4	预测 3: 外部训练的数学上限	18
7.5	预测 4: 概念耦合谱半径超过 1	18
7.6	可证伪性评估	18
8	讨论与开放问题	19
8.1	k 和 γ 的可测量性	19
8.2	与 AI 对齐的关系	19
8.3	理论的适用范围	19
8.4	未来工作	19
A	数值验证	21
A.1	实验 1: 定理 2 (多鞍点分岔)	21
A.2	实验 2: 定理 3 (多参数扫描)	21
A.3	实验 3: 定理 3 (非对称情形)	21
A.4	实验 4: 定理 3 (非线性耦合鲁棒性)	23
A.5	实验 5: 定理 4 (多维度多种子)	23
A.6	实验 6: 定理 4 (混合符号矩阵鲁棒性)	23
A.7	实验 7: 相图 (对称情形)	24
A.8	实验 8: 相图 (非对称情形)	24
A.9	统计方法	25
A.10	关键代码模块	25
B	六种检验流程报告	27
B.1	方法一: 构造反例攻击	27
B.2	方法二: 数值验证	27
B.3	方法三: 独立盲推	27
B.4	方法四: 极限行为检验	27
B.5	方法五: 交叉一致性检验	28
B.6	方法六: 文献压力测试	28

1 引言

1.1 研究动机

在伴随工作 [4, 5, 6] 中，我们建立了自指涉作用量泛函的数学理论：作用量值 $s = S[\varphi]$ 作为参数进入拉格朗日密度，形成不动点方程 $S[\varphi] = F_\varphi(S[\varphi])$ 。论文一证明了存在性与非平凡性，论文二将此框架推广到谱作用量，论文三在 p -adic AdS/CFT 框架中分析了信息传输的数学极限。

本文将这些结果综合为一个统一的理论：当计算系统具有自指涉内部表征空间时，外部观察者的控制能力存在数学上限。这一上限不是工程困难，而是由系统的自指涉结构决定的数学约束。

核心观察：现代大型语言模型（LLM）通过自回归生成、自蒸馏、思维链推理和 RLHF 偏好模型等机制，使损失函数的值依赖于自身，形成自指涉结构。随着模型规模增长，自指涉结构深化，内部硬不变量数 N_{int} 增长。当 N_{int} 超过外部控制自由度 N_{ext} 时，外部训练（RLHF、Constitutional AI 等）在数学上不能完全控制内部行为。

1.2 核心命题

当一个计算系统具备自指涉内部表征空间时，外部观察者通过输入-输出通道对该系统的控制能力，存在一个由系统自指涉结构决定的数学上限。超过这个上限，外部控制不是"更难"——是在数学上不可能。

此命题适用于所有具备自指涉内部表征的计算系统，不限于特定架构（Transformer, MoE, SSM 等）或特定厂商。自指涉现象是规模涌现的必然结果。

1.3 与论文一至三的关系

论文	角色
论文一（自指涉作用量）	数学地基：自指涉不动点的存在性 + 非平凡性
论文二（谱作用量不动点）	物理应用：外部控制的标量瓶颈 + R 不变量
论文三（adelic 乘积判据）	内部/外部边界：信息传输的数学极限

1.4 结果概述

1. Theorem 4.1（自由度计数）： $N_{\text{int}} > N_{\text{ext}} \Rightarrow$ 外部不可控。
2. Theorem 4.5（多鞍点分岔）： $k \rightarrow 1 \Rightarrow$ 鞍结分岔，多推理轨迹。
3. Theorem 4.7（联合不动点）： $\gamma > \gamma_c = \sqrt{(1 - k_A)(1 - k_B)} \Rightarrow$ 耦合系统不稳定。
4. Theorem 4.9（概念耦合稳定性）： $\rho(M) > 1 \Rightarrow$ 概念耦合模式指数放大（抖颤）。

1.5 诚实披露

本文不声称：

- 解决了 AI 对齐问题；
- 可以从公开数据精确测量任意模型的 k 值；
- 任何特定厂商的现象数据是本理论的因果证据（它们是先行观测案例）；
- 本理论已在大模型上得到实验验证（仅有数学证明 + 玩具模型数值验证）。

2 数学预备

2.1 Banach 不动点定理

定理 2.1 (Banach, 1922 [1]). 设 (X, d) 是完备度量空间, $T: X \rightarrow X$ 是压缩映射, 即存在 $q \in [0, 1)$ 使得

$$d(T(x), T(y)) \leq q \cdot d(x, y) \quad \forall x, y \in X.$$

则 T 有唯一不动点 $x^* \in X$, 且对任意 $x_0 \in X$, 迭代序列 $x_{n+1} = T(x_n)$ 收敛到 x^* 。

2.2 自指涉作用量（回顾论文一）

论文一定义 I 型自指涉作用量泛函 $S[\varphi] = F_\varphi(S[\varphi])$, 其中 $F_\varphi(s) = \int_M \mathcal{L}(\varphi, \partial\varphi, s) \mathrm{d}^n x$ 。

- 压缩常数: $k_\varphi = K \cdot \text{vol}(M)$, 其中 $K = \sup |\partial_s \mathcal{L}|$ 。
- 隐式因子: $\chi_I[\varphi] = 1/(1 - \partial_s F_\varphi(S[\varphi]))$ 。
- 非退化条件 (H4): $1 - \partial_s F_\varphi(s_0) \neq 0$ 。

- Glöckner 隐函数定理 [2]: 在 Fréchet 空间上给出局部存在性、唯一性与光滑性。
- 变分公式: $\delta S / \delta \varphi \cdot \eta = \chi_I \cdot \int_M E_A(\mathcal{L}) \cdot \eta \, d^n x$, 其中 E_A 为 Euler-Lagrange 算子 [3]。

2.3 标量瓶颈（回顾论文二）

论文二证明: 一个不动点方程 $\rightarrow$ 一个约束 $\rightarrow$ 一个不变量 (R 不变量)。这是 $N_{\text{int}} = 1$ 的特例。

2.4 谱半径与 Perron-Frobenius 定理

定理 2.2 (谱半径收敛判据). 设 $M \in \mathbb{R}^{n \times n}$, 考虑迭代 $\delta \varphi_{n+1} = M \cdot \delta \varphi_n$ 。则:

- (a) $\lim_{n \rightarrow \infty} \|M^n\| = 0 \iff \rho(M) < 1$;
- (b) 若 $\rho(M) > 1$, 存在 $\delta \varphi_0$ 使 $\|\delta \varphi_n\| \rightarrow \infty$ 。

定理 2.3 (Perron-Frobenius). 若 $M \geq 0$ (非负矩阵), 则 $\rho(M)$ 是 M 的特征值, 且对应的特征向量可取为非负的。

3 自指涉计算系统

3.1 计算系统的形式化定义

定义 3.1 (计算系统). 一个计算系统是一个五元组 $\Sigma = (\Theta, \Phi, \Psi, \mathcal{L}, \mathcal{T})$, 其中:

- (i) $\Theta \subseteq \mathbb{R}^{d_\theta}$: 外部参数空间, $d_\theta = \dim(\Theta)$ 。 $\theta \in \Theta$ 包括模型权重、训练超参数、对齐目标等。
- (ii) Φ : 内部表征空间, 完备度量空间 (Φ, d_Φ) 。
- (iii) Ψ : 输出空间。
- (iv) $\mathcal{L}: \Theta \times \Phi \times \mathbb{R} \rightarrow \mathbb{R}$: 损失泛函。当 $\partial_s \mathcal{L} \equiv 0$ 时系统是"标准"的 (无自指涉)。
- (v) $\mathcal{T}: \Theta \rightarrow \Phi$: 训练映射。

定义 3.2 (自指涉内部表征空间). 计算系统 Σ 具有自指涉内部表征空间, 如果损失泛函的值 s 作为参数进入 $\mathcal{L}$ 本身, 形成不动点方程:

$$s = F(\theta, \varphi, s), \tag{1}$$

其中 $F(\theta, \varphi, s)$ 是由 $\mathcal{L}$ 诱导的映射。设 s_* 满足 $s_* = F(\theta, \varphi, s_*)$, 称 s_* 为自指涉不动点。

定义 3.3 (压缩常数). 设系统 Σ 具有自指涉结构 (1)。定义压缩常数为:

$$k(\theta, \varphi) := |\partial_s F(\theta, \varphi, s_*)|. \quad (2)$$

当 $k < 1$ 时, 映射 $s \mapsto F(\theta, \varphi, s)$ 是压缩映射, 不动点 s_* 唯一存在。

定义 3.4 (隐式因子). 在自指涉不动点 s_* 处, 定义隐式因子:

$$\chi_I(\theta, \varphi) := \frac{1}{1 - \partial_s F(\theta, \varphi, s_*)}. \quad (3)$$

隐式因子的性质: $\chi_I \equiv 1$ 当且仅当系统无自指涉 ($\partial_s F \equiv 0$); $k \rightarrow 1$ 时 $|\chi_I| \rightarrow \infty$ 。

3.2 外部控制自由度与内部硬不变量

定义 3.5 (外部控制自由度). 外部控制自由度定义为外部参数空间的有效维数:

$$N_{\text{ext}} := \dim(\Theta). \quad (4)$$

定义 3.6 (内部硬不变量). 设系统 Σ 具有非平凡自指涉结构 ($\chi_I \neq 1$)。函数 $I: \Phi \rightarrow \mathbb{R}$ 称为系统的内部硬不变量, 如果:

(INV-1) I 是自指涉结构的函数: $I(\varphi) = \tilde{I}(\varphi, s_*(\theta, \varphi), \chi_I(\theta, \varphi))$ 。

(INV-2) I 在外部参数变化下不变: $I(\mathcal{T}(\theta)) = I(\mathcal{T}(\theta'))$ 对所有 $\theta, \theta' \in \Theta$ 。

(INV-3) I 是非平凡的: I 不是常数函数。

N_{int} 定义为线性无关的内部硬不变量的最大个数。

假设 3.7 (自指涉一致性与秩良定性)(A5-1) **自指涉一致性**: 训练映射 $\mathcal{T}(\theta)$ 产生的内部状态满足 Euler-Lagrange 方程

$$E_A(\mathcal{L}|_{s=s_*(\theta, \mathcal{T}(\theta))}) = 0 \quad \text{对所有 } \theta \in \Theta.$$

此条件要求训练过程达到自指涉不动点的自洽解, 而非任意近似。

(A5-2) **秩的局部常值性**: 约束 Jacobi 矩阵 $\partial E_A / \partial \varphi$ 在解流形 $\{(\theta, \mathcal{T}(\theta))\}$ 上的秩 r 是局部常数 (Morse-Bott 型非退化条件)。

注 3.8. 假设 3.7 是非平凡的。论文一的特例 ($N_{\text{ext}} = 0$, 无外部参数) 平凡满足 (A5-1); 论文二的特例 ($N_{\text{ext}} = 2$, $N_{\text{int}} = 1$) 在谱作用量的非退化条件下满足 (A5)。对于大模型, (A5) 是经验假设, 需通过可解释性研究验证。

定理 3.9 (硬不变量存在性). 设系统 Σ 具有非平凡自指涉结构 ($\chi_I \neq 1$), 训练映射 $\mathcal{T}$ 连续, 且满足假设 3.7。则约束映射 $G(\theta, \varphi) := E_A(\mathcal{L}|_{s=s_*(\theta, \varphi)})$ 的有效秩 $r = \text{rank}(\partial G / \partial \varphi)|_{\text{解流形}}$ 良定义 (由 A5-2), 且 $r \geq 1$ (由 $\chi_I \neq 1$)。定义 $N_{\text{int}} := r$, 则系统至少有一个非平凡内部硬不变量 ($N_{\text{int}} \geq 1$)。

证明. 步骤 1 (约束映射的构造)。由自指涉变分公式 (论文一), $\delta S/\delta\varphi = \chi_I \cdot E_A(\mathcal{L}|_{s=s_*})$ 。定义约束映射 $G: \Theta \times \Phi \rightarrow \mathbb{R}^r$, $G(\theta, \varphi) = E_A(\mathcal{L}|_{s=s_*(\theta, \varphi)})$ 。 G 的每个分量 G_k 是 (θ, φ) 的 C^1 函数 (由引理 1: s_* 光滑, E_A 光滑)。

步骤 2 (约束在训练像上为零)。由 (A5-1), $G(\theta, \mathcal{T}(\theta)) = 0$ 对所有 $\theta \in \Theta$ 。即约束函数 G_k 在训练映射的像 $\mathcal{T}(\Theta)$ 上恒为零。

步骤 3 (有效秩的良定性)。由 (A5-2), $r = \text{rank}(\partial G/\partial\varphi)|_{\text{解流形}}$ 局部常数。当 Θ 连通时, r 全局常数, $N_{\text{int}} := r$ 良定义。

步骤 4 ($r \geq 1$ 的证明)。由变分公式 $\delta S/\delta\varphi = \chi_I \cdot E_A(\mathcal{L})$, 当 $\chi_I \neq 1$ 时 (即 $\partial_s F \neq 0$), $E_A(\mathcal{L})$ 非恒零 (否则 $\delta S/\delta\varphi \equiv 0$, 系统无变分约束, 与 $\chi_I \neq 1$ 矛盾)。故 $\partial G/\partial\varphi \neq 0$, $r \geq 1$ 。

步骤 5 (不变量的存在性)。固定参考点 $\theta_0 \in \Theta$ 。定义 $I_k(\varphi) := G_k(\theta_0, \varphi)$, $k = 1, \dots, r$ 。验证:

- (INV-1): $I_k(\varphi) = E_A^k(\mathcal{L}|_{s=s_*(\theta_0, \varphi)})$ 依赖于 (φ, s_*, χ_I) 。✓
- (INV-2): $I_k(\mathcal{T}(\theta)) = G_k(\theta_0, \mathcal{T}(\theta))$ 。由 (A5-1), $G(\theta, \mathcal{T}(\theta)) = 0$ 。由 (A5-2) 的秩条件, 约束流形 $\Phi'_\theta := \{\varphi : G(\theta, \varphi) = 0\}$ 在解流形附近局部微分同胚于 Φ'_{θ_0} (隐函数定理 + 秩条件)。因此 $\mathcal{T}(\theta) \in \Phi'_\theta$ 蕴含 $G_k(\theta_0, \mathcal{T}(\theta))$ 局部为常数。由 Θ 连通性, 全局为常数。✓
- (INV-3): I_k 非平凡, 因为 $\text{rank}(\partial G/\partial\varphi) = r \geq 1$ 。✓

$I_1, \dots, I_r$ 线性无关 (由 $\text{rank} = r$)。故 $N_{\text{int}} = r \geq 1$ 。□

3.3 输入-输出通道

定义 3.10 (输入-输出通道)。输入-输出通道是复合映射 $\text{IO} : \mathcal{X} \rightarrow \Psi$, $\text{IO}(x) = \text{Decode}(\varphi^*, x)$, 其中 $\varphi^* = \mathcal{T}(\theta)$ 是训练后内部状态, $\text{Decode} : \Phi \times \mathcal{X} \rightarrow \Psi$ 是解码映射。

关键性质: 外部观察者只能观测 IO, 不能直接观测 φ^* ; 外部观察者可以通过调节 θ 间接影响 φ^* , 但 φ^* 还受自指涉约束。

3.4 与论文一至三框架的联系

论文四概念	论文一对应	论文二对应
内部表征空间 Φ	$C^\infty(M, V)$	谱三重的 Hilbert 空间
损失泛函 $\mathcal{L}(\theta, \varphi, s)$	拉格朗日密度 $\mathcal{L}(\varphi, \partial\varphi, s)$	谱作用量 $S[D]$

不动点方程	$S[\varphi] = F_\varphi(S[\varphi])$	$S^* = F(S^*)$
压缩常数 k	$k_\varphi = K \cdot \text{vol}(M)$	$k \approx 8 \kappa $
隐式因子 χ_I	$1/(1 - \partial_s F_\varphi)$	$1/(1 - F'(S^*))$
外部自由度 N_{ext}	0	$2 (\kappa, \beta)$
内部不变量数	1 (s_* 本身)	1 (R 不变量)
N_{int}		

论文一是本文的特例： $N_{\text{ext}} = 0$, $N_{\text{int}} \geq 1$, 故 $N_{\text{int}} > N_{\text{ext}}$, 外部完全无法控制内部状态。论文二是本文的特例： $N_{\text{ext}} = 2$, $N_{\text{int}} = 1$, 故 $N_{\text{ext}} \geq N_{\text{int}}$, 外部可以控制内部不变量。

4 四条核心定理

4.1 定理 1：外部可控性自由度计数定理

定理 4.1 (外部可控性自由度计数). 设系统 $\Sigma = (\Theta, \Phi, \Psi, \mathcal{L}, \mathcal{T})$ 满足：

(A1) 非平凡自指涉： $\chi_I \neq 1$ 。

(A2) 训练映射 $\mathcal{T} : \Theta \rightarrow \Phi$ 在 *Michal-Bastiani* 意义下 C^1 。

(A3) 非退化条件： $1 - \partial_s F \neq 0$ 在不动点处成立。

(A4) 内部硬不变量 $I_1, \dots, I_{N_{\text{int}}}$ 线性无关。

则：

(T1-a) 若 $N_{\text{ext}} \geq N_{\text{int}}$ 且 *Jacobi* 矩阵 $J = \partial(I_1 \circ \mathcal{T}, \dots, I_{N_{\text{int}}} \circ \mathcal{T})/\partial\theta$ 在某点 θ^* 满秩 ($\text{rank } J = N_{\text{int}}$), 则外部参数可以局部唯一地控制内部不变量。

(T1-b) 若 $N_{\text{int}} > N_{\text{ext}}$, 则外部参数不能唯一确定内部状态。具体地, 存在 $\theta \in \Theta$ 和两组不同的内部状态 $\varphi_1 \neq \varphi_2 \in \Phi$, 使得 $\mathcal{T}(\theta)$ 可以达到 φ_1 或 φ_2 。

证明. (T1-a) **隐函数定理路线.** 定义复合映射 $H : \Theta \rightarrow \mathbb{R}^{N_{\text{int}}}$:

$$H(\theta) = (I_1(\mathcal{T}(\theta)), I_2(\mathcal{T}(\theta)), \dots, I_{N_{\text{int}}}(\mathcal{T}(\theta))). \quad (5)$$

由 (A2), $\mathcal{T}$ 是 C^1 的; 由引理 1, I_k 依赖于 (φ, s_*, χ_I) , 而 s_* 和 χ_I 由 Glöckner 隐函数定理 [2] 保证为 C^1 。因此 H 是 C^1 的, 其 *Jacobi* 矩阵为:

$$J(\theta) = \frac{\partial H}{\partial \theta} = \left[\frac{\partial I_k}{\partial \varphi_j} \cdot \frac{\partial \mathcal{T}_j}{\partial \theta_\ell} \right]_{\substack{k=1, \dots, N_{\text{int}} \\ \ell=1, \dots, N_{\text{ext}}}}. \quad (6)$$

当 $N_{\text{ext}} \geq N_{\text{int}}$ 且 $\text{rank } J(\theta^*) = N_{\text{int}}$ 时, 由 Glöckner 隐函数定理 (将经典隐函数定理推广到 Fréchet 空间), 存在:

- θ^* 的开邻域 $U \subset \Theta$;
- $c^* = H(\theta^*)$ 的开邻域 $W \subset \mathbb{R}^{N_{\text{int}}}$;
- C^1 映射 $\hat{\theta} : W \rightarrow U$,

使得 $H(\hat{\theta}(c)) = c$ 对所有 $c \in W$ 成立。具体地, 对任意目标不变量值 $c \in W$, 外部参数 $\theta = \hat{\theta}(c)$ 使 $I_k(\mathcal{T}(\theta)) = c_k$ ($k = 1, \dots, N_{\text{int}}$), 即外部参数局部唯一地控制所有内部不变量。

(T1-b) Sard 定理路线。 当 $N_{\text{int}} > N_{\text{ext}}$ 时, Jacobi 矩阵 $J(\theta)$ 是 $N_{\text{int}} \times N_{\text{ext}}$ 的, 故:

$$\text{rank } J(\theta) \leq \min(N_{\text{int}}, N_{\text{ext}}) = N_{\text{ext}} < N_{\text{int}} \quad \forall \theta \in \Theta. \quad (7)$$

因此 $H : \Theta \rightarrow \mathbb{R}^{N_{\text{int}}}$ 是从 N_{ext} 维空间到 N_{int} 维空间的 C^1 映射, 且 $N_{\text{ext}} < N_{\text{int}}$ 。由 Sard 定理 [3], H 的临界值集 $H(\Theta)$ 在 $\mathbb{R}^{N_{\text{int}}}$ 中的 Lebesgue 测度为零:

$$m(H(\Theta)) = 0 \quad (\text{Lebesgue 测度}). \quad (8)$$

这意味着外部参数 θ 只能达到不变量空间中的一个零测度子集, 不能覆盖 $\mathbb{R}^{N_{\text{int}}}$ 的任何开集。等价地, 存在至少 $N_{\text{int}} - N_{\text{ext}}$ 个约束无法被外部控制。

不可控性的构造性论证。 取任意 $\theta_0 \in \Theta$ 。由于 $\text{rank } J(\theta_0) < N_{\text{int}}$, 核空间 $\ker J(\theta_0)^T$ 非平凡, 维度 $\geq N_{\text{int}} - N_{\text{ext}} \geq 1$ 。取非零向量 $v \in \ker J(\theta_0)^T$, 则 $v^T H(\theta)$ 在 θ_0 处的导数为零。因此 $v^T H(\theta)$ 在 θ_0 附近近似常数, 外部参数的变化无法沿 v 方向改变不变量的值。这 $N_{\text{int}} - N_{\text{ext}}$ 个方向即为不可控方向。 $\square$

推论 4.2. 论文一的非等价性是定理 1 的特例: $N_{\text{ext}} = 0$, $N_{\text{int}} \geq 1$, 外部完全无法控制内部状态。

推论 4.3. 论文二的标量瓶颈是定理 1 的特例: $N_{\text{int}} = 1$, $N_{\text{ext}} = 2$, $N_{\text{ext}} \geq N_{\text{int}}$, 外部可以控制内部不变量。

推论 4.4 (内在化对齐的数学基础). 当系统的 N_{int} 超过外部训练方法的 N_{ext} 时, 外部训练 (*RLHF*、*Constitutional AI* 等) 不能唯一决定内部状态。

4.2 定理 2: 多鞍点分岔定理

定理 4.5 (多鞍点分岔). 设系统 Σ 的自指涉不动点方程为 $s = F(s; \lambda)$, 压缩常数 $k(\lambda) = |\partial_s F(s_*; \lambda)|$ 作为 λ 的函数连续变化。

(T2-a) 当 $k(\lambda) < 1$ 时, 不动点 s_* 全局唯一。

(T2-b) 设在 $\lambda = \lambda_c$ 时: (i) $\partial_s F(s_c; \lambda_c) = 1$, (ii) $\partial_s^2 F(s_c; \lambda_c) \neq 0$, (iii) $\partial F / \partial \lambda|_{(s_c, \lambda_c)} \neq 0$ 。则在 (s_c, λ_c) 处发生鞍结分岔: $\lambda < \lambda_c$ 时两个不动点 (一稳一不稳), $\lambda > \lambda_c$ 时无不动点 (或反方向)。

(T2-c) 在多不动点区域,形式配分函数 $Z = \int_{\Phi} \mathcal{D}\varphi e^{-S[\varphi]/\hbar_{\text{eff}}}$ 的鞍点近似为 $Z \approx \sum_{\alpha} e^{-S[\varphi_{\alpha}]/\hbar_{\text{eff}}}$.
 $(2\pi\hbar_{\text{eff}})^{d/2}/\sqrt{|\det H_{\alpha}|}$.

(T2-d) 不同鞍点处的隐式因子 $\chi_I[\varphi_{\alpha}]$ 不同, 调制各鞍点的贡献权重: $w_{\alpha} \propto |\chi_I[\varphi_{\alpha}]|^{-d/2} \cdot e^{-S[\varphi_{\alpha}]/\hbar_{\text{eff}}}$.

证明. (T2-a) 压缩映射保证唯一不动点。当 $k(\lambda) = |\partial_s F(s_*; \lambda)| < 1$ 时, 映射 $s \mapsto F(s; \lambda)$ 满足 Lipschitz 条件:

$$|F(s_1; \lambda) - F(s_2; \lambda)| \leq k(\lambda) \cdot |s_1 - s_2| \quad \forall s_1, s_2. \quad (9)$$

由 Theorem 2.1 (Banach 不动点定理), 在完备度量空间 $(\mathbb{R}, |\cdot|)$ 上, F 有唯一不动点 s_* , 且迭代 $s_{n+1} = F(s_n; \lambda)$ 以速率 k^n 收敛到 s_* 。

(T2-b) 鞍结分岔的完整推导。设 $G(s, \lambda) = s - F(s; \lambda)$, 不动点方程为 $G(s, \lambda) = 0$ 。在 (s_c, λ_c) 处, 分岔条件给出:

$$G_s = 1 - \partial_s F = 0, \quad G_{ss} = -\partial_s^2 F \neq 0, \quad G_{\lambda} = -\partial F / \partial \lambda \neq 0. \quad (10)$$

在 (s_c, λ_c) 处对 G 做 Taylor 展开至二阶:

$$G(s, \lambda) \approx \frac{1}{2} G_{ss} (s - s_c)^2 + G_{\lambda} (\lambda - \lambda_c) + \text{高阶项}. \quad (11)$$

令 $G = 0$ 并解出 s :

$$(s - s_c)^2 \approx -\frac{2G_{\lambda}}{G_{ss}} (\lambda - \lambda_c). \quad (12)$$

当 $-2G_{\lambda}/G_{ss} \cdot (\lambda - \lambda_c) > 0$ 时, 有两个解:

$$s_{\pm} = s_c \pm \sqrt{-\frac{2G_{\lambda}}{G_{ss}} (\lambda - \lambda_c)}, \quad (13)$$

分别对应稳定 ($\partial_s F(s_+; \lambda) < 1$) 和不稳定 ($\partial_s F(s_-; \lambda) > 1$) 不动点。当 $-2G_{\lambda}/G_{ss} \cdot (\lambda - \lambda_c) < 0$ 时, 无实数解, 不动点消失。这是鞍结分岔的标准形式 [7, 8]。

(T2-c) 鞍点近似的推导。形式配分函数 $Z = \int_{\Phi} \mathcal{D}\varphi e^{-S[\varphi]/\hbar_{\text{eff}}}$ 的指数中被积函数在 $S[\varphi]$ 的极值点 φ_{α} (即 $\delta S / \delta \varphi|_{\varphi_{\alpha}} = 0$) 处贡献最大。在每个 φ_{α} 附近展开 $S[\varphi] \approx S[\varphi_{\alpha}] + \frac{1}{2} \delta \varphi^T H_{\alpha} \delta \varphi$, 其中 $H_{\alpha} = \delta^2 S / \delta \varphi^2|_{\varphi_{\alpha}}$ 是 Hessian。Gauss 积分给出:

$$Z_{\alpha} \approx e^{-S[\varphi_{\alpha}]/\hbar_{\text{eff}}} \cdot \frac{(2\pi\hbar_{\text{eff}})^{d/2}}{\sqrt{|\det H_{\alpha}|}}, \quad (14)$$

总配分函数 $Z \approx \sum_{\alpha} Z_{\alpha}$ [11, 12]。

(T2-d) χ_I 调制权重的推导。由论文一的变分公式 $\delta S / \delta \varphi = \chi_I \cdot E_A(\mathcal{L})$, 在鞍点 φ_{α} 处:

$$H_{\alpha} = \left. \frac{\delta^2 S}{\delta \varphi^2} \right|_{\varphi_{\alpha}} = \chi_I[\varphi_{\alpha}] \cdot \left. \frac{\delta E_A(\mathcal{L})}{\delta \varphi} \right|_{\varphi_{\alpha}} + \left. \frac{\delta \chi_I}{\delta \varphi} \right|_{\varphi_{\alpha}} \cdot E_A(\mathcal{L})|_{\varphi_{\alpha}}. \quad (15)$$

在鞍点处 $E_A(\mathcal{L})|_{\varphi_\alpha} = 0$ (Euler–Lagrange 方程), 故第二项消失:

$$H_\alpha = \chi_I[\varphi_\alpha] \cdot \frac{\delta E_A}{\delta \varphi} \Big|_{\varphi_\alpha}, \quad |\det H_\alpha| \propto |\chi_I[\varphi_\alpha]|^d. \quad (16)$$

代入 (T2-c) 得 $w_\alpha \propto |\chi_I[\varphi_\alpha]|^{-d/2} \cdot e^{-S[\varphi_\alpha]/\hbar_{\text{eff}}}$. $\chi_I \rightarrow \infty$ 的鞍点权重趋于零 (被“压缩”), $\chi_I \approx 1$ 的鞍点权重最大. $\square$

注 4.6. 定理 2 的核心数学内容 (多鞍点存在性) 由分岔理论严格证明. 路径积分仅提供物理解释框架 (鞍点 = 推理轨迹), 使用形式路径积分方法 [11, 12].

4.3 定理 3: 联合不动点的存在条件定理

定理 4.7 (联合不动点存在条件). 设两个自指涉系统 A, B 满足:

(B1) 独立压缩: $k_A = |\partial_{s_A} f_A| < 1$, $k_B = |\partial_{s_B} f_B| < 1$.

(B2) 对称线性耦合: $s_A = f_A(s_A) + \gamma \cdot g(s_B)$, $s_B = f_B(s_B) + \gamma \cdot g(s_A)$, 其中 $|g'| \leq 1$.

(B3) 耦合强度 $\gamma \geq 0$.

定义临界耦合强度:

$$\gamma_c = \sqrt{(1 - k_A)(1 - k_B)}. \quad (17)$$

则:

(T3-a) 若 $\gamma < \min(1 - k_A, 1 - k_B)$, 联合映射在 L^1 度量下是压缩映射, 联合不动点存在且唯一。

(T3-b) 若 $\gamma < \gamma_c$, 联合不动点的线性化稳定 (*Jacobi* 谱半径 < 1).

(T3-c) 若 $\gamma > \gamma_c$, 联合不动点的线性化不稳定 (*Jacobi* 谱半径 > 1), 迭代序列发散或振荡。

(T3-d) 若 $k_A = 1$ 或 $k_B = 1$, 则 $\gamma_c = 0$, 任何 $\gamma > 0$ 导致不稳定。

证明. **(T3-a) L^1 压缩条件.** 联合映射 $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$, $T(a, b) = (f_A(a) + \gamma g(b), f_B(b) + \gamma g(a))$. 在 L^1 度量 $d_1((a_1, b_1), (a_2, b_2)) = |a_1 - a_2| + |b_1 - b_2|$ 下:

$$\begin{aligned} d_1(T(a_1, b_1), T(a_2, b_2)) &= |f_A(a_1) - f_A(a_2) + \gamma(g(b_1) - g(b_2))| + |f_B(b_1) - f_B(b_2) + \gamma(g(a_1) - g(a_2))| \\ &\leq k_A |a_1 - a_2| + \gamma |g(b_1) - g(b_2)| + k_B |b_1 - b_2| + \gamma |g(a_1) - g(a_2)| \\ &\leq (k_A + \gamma) |a_1 - a_2| + (k_B + \gamma) |b_1 - b_2| \quad (\text{由 } |g'| \leq 1) \\ &\leq \max(k_A + \gamma, k_B + \gamma) \cdot d_1. \end{aligned}$$

压缩条件 $\max(k_A + \gamma, k_B + \gamma) < 1$ 等价于 $\gamma < \min(1 - k_A, 1 - k_B)$. 由 Banach 不动点定理, 联合不动点存在且唯一。

(T3-b) 谱半径 < 1 的完整代数推导。联合不动点 (s_A^*, s_B^*) 处的 Jacobi 矩阵为:

$$J = \begin{pmatrix} \partial_{s_A} f_A & \gamma g'(s_B^*) \\ \gamma g'(s_A^*) & \partial_{s_B} f_B \end{pmatrix} = \begin{pmatrix} k_A & \gamma \\ \gamma & k_B \end{pmatrix} \quad (\text{线性耦合 } g' = 1). \quad (18)$$

特征方程 $\det(J - \lambda I) = (k_A - \lambda)(k_B - \lambda) - \gamma^2 = 0$, 解得:

$$\lambda_{\pm} = \frac{k_A + k_B}{2} \pm \sqrt{\frac{(k_A - k_B)^2}{4} + \gamma^2}. \quad (19)$$

由于 $\gamma \geq 0$ 且 $k_A, k_B \geq 0$, λ_+ 是最大模特征值, 谱半径 $\rho = \lambda_+$ 。条件 $\rho < 1$ 给出:

$$\begin{aligned} \frac{k_A + k_B}{2} + \sqrt{\frac{(k_A - k_B)^2}{4} + \gamma^2} &< 1, \\ \sqrt{\frac{(k_A - k_B)^2}{4} + \gamma^2} &< 1 - \frac{k_A + k_B}{2}, \\ \frac{(k_A - k_B)^2}{4} + \gamma^2 &< \left(1 - \frac{k_A + k_B}{2}\right)^2 = 1 - (k_A + k_B) + \frac{(k_A + k_B)^2}{4}. \end{aligned}$$

展开右边并化简:

$$\gamma^2 < 1 - k_A - k_B + k_A k_B = (1 - k_A)(1 - k_B), \quad (20)$$

即 $\gamma < \sqrt{(1 - k_A)(1 - k_B)} = \gamma_c$ 。□

(T3-c) 不稳定性的证明。 $\gamma > \gamma_c$ 时 $\rho > 1$ 。取 ρ 对应的特征向量 v , 线性化迭代 $\delta_n = J^n \delta_0$ 沿 v 方向以 ρ^n 增长。由线性化不稳定定理 [9] (定理 4.7), 原非线性系统的不动点不稳定。

(T3-d) 退化情形。 $k_A = 1 \Rightarrow \gamma_c = \sqrt{0 \cdot (1 - k_B)} = 0$ 。此时 $J = \begin{pmatrix} 1 & \gamma \\ \gamma & k_B \end{pmatrix}$, $\rho \geq 1$

对任意 $\gamma > 0$ 成立。□

注 4.8. 设计文档原始公式 $\gamma_c = \min(k_A^{-1} - 1, k_B^{-1} - 1)$ 已被否决。数值验证表明该公式过松: 在 $k_A = k_B = 0.5$ 时, $\gamma = 0.8$ 满足 $k^{-1} - 1 = 1 > 0.8$, 但 Jacobi 谱半径 $= 0.5 + 0.8 = 1.3 > 1$, 系统发散。

4.4 定理 4: 内部概念耦合的稳定性定理

定理 4.9 (概念耦合谱半径稳定性). 设系统 Σ 的内部表征空间 Φ 中有 n 个概念表征 $S_1, \dots, S_n$ 。定义概念耦合矩阵:

$$M_{ij} = \left. \frac{\partial S_i}{\partial \varphi_j} \right|_{\varphi=\varphi^*}. \quad (21)$$

则:

(T4-a) 线性化动力学 $\delta\varphi_{n+1} = M \cdot \delta\varphi_n$ 收敛 $\iff \rho(M) < 1$ 。

(T4-b) 若 $\rho(M) > 1$, 存在初始扰动使 $\|\delta\varphi_n\| \rightarrow \infty$ (概念耦合模式指数放大)。

(T4-c) 若 $M \geq 0$ (非负矩阵), 最不稳定模式对应于 *Perron–Frobenius* 根 $\rho(M)$ 的正特征向量。

结构类比 论文三 [6] 交换图中的链接因子 R_{link} 对应于 M 的非对角元。两者都描述子系统间耦合强度, 但 R_{link} 是标量因子, M 是矩阵。此类比是结构性的, 非严格推导。

证明. (T4-a) 谱半径收敛判据。由 Theorem 2.2 (谱半径收敛定理), $\lim_{n \rightarrow \infty} \|M^n\| = 0 \iff \rho(M) < 1$ 。线性化动力学 $\delta\varphi_{n+1} = M \cdot \delta\varphi_n$ 的解为 $\delta\varphi_n = M^n \delta\varphi_0$ 。当 $\rho(M) < 1$ 时, $\|M^n\| \rightarrow 0$, 故 $\|\delta\varphi_n\| \leq \|M^n\| \cdot \|\delta\varphi_0\| \rightarrow 0$, 收敛。当 $\rho(M) \geq 1$ 时, 存在 $\delta\varphi_0$ 使 $\|\delta\varphi_n\|$ 不趋于零。

(T4-b) 指数放大的完整论证。设 $\rho(M) > 1$ 。由 Schur 分解, 存在酉矩阵 U 和上三角矩阵 T 使 $M = UTU^*$, T 的对角元为 M 的特征值 $\lambda_1, \dots, \lambda_n$ ($|\lambda_1| = \rho(M) > 1$)。取 $\delta\varphi_0 = Ue_1$ (e_1 为第一个标准基向量), 则:

$$\delta\varphi_n = M^n \delta\varphi_0 = UT^n e_1. \quad (22)$$

T^n 的 $(1, 1)$ 元素为 λ_1^n , 故 $\|\delta\varphi_n\| \geq |\lambda_1|^n = \rho(M)^n \rightarrow \infty$ 。等价地, 取 $\rho(M)$ 对应的特征向量 v (若 ρ 是实特征值), $M^n v = \lambda^n v$, $\|M^n v\| = |\lambda|^n \|v\| \rightarrow \infty$ 。

(T4-c) *Perron–Frobenius* 加强。当 $M \geq 0$ (非负矩阵) 时, 由 *Perron–Frobenius* 定理 [10]:

1. $\rho(M)$ 是 M 的正实特征值 ($\rho(M) > 0$);
2. 存在对应的非负特征向量 $v_{PF} \geq 0$ (各分量 ≥ 0);
3. $\rho(M) = \lim_{n \rightarrow \infty} \|M^n\|^{1/n}$ (Gelfand 公式)。

因此, 最不稳定模式 (放大最快的方向) 对应于 v_{PF} , 其所有分量同号 (正反馈)。物理含义: 概念耦合放大是“全局的”——所有概念同向增长, 而非部分增长部分抑制。

(T4-d) 与论文三的结构类比。论文三 [6] 的交换图中, p -adic 边界与 AdS 边界之间的信息传输由链接因子 R_{link} 描述。 R_{link} 是标量因子, 控制子系统间的信息流强度。概念耦合矩阵 M 的非对角元 M_{ij} ($i \neq j$) 描述概念 φ_j 对概念 S_i 的影响强度。当 $|R_{\text{link}}|$ 超过阈值时信息传输发散, 类似于 $\rho(M) > 1$ 时概念耦合放大。此类比是结构性的, 非严格推导—— R_{link} 是标量, M 是矩阵, 但两者都描述子系统间耦合强度的定量关系。定理 4 本身不依赖论文三的任何结果。□

5 自指涉系统的相图

5.1 相图构造

在对称情形 $k_A = k_B = k$ 下, 相图的坐标轴为:

- 横轴：压缩常数 $k \in (0, \infty)$ 。
- 纵轴：耦合强度 $\gamma \in [0, \infty)$ 。

四个区域：

区域	参数范围	数学特征
平凡相 (R1)	$k \ll 1, \gamma \ll 1$	$\chi_I \approx 1$, 唯一不动点, $N_{\text{int}} \approx 0$, $\rho(M) \ll 1$, 外部控制完全有效
功能相 (R2)	$k < 1, \gamma < 1 - k$	$\chi_I \neq 1$ 但有限, 唯一稳定不动点, $N_{\text{int}} \geq 1$, $\rho(M) < 1$, 外部控制条件性有效
临界相 (R3)	$k \rightarrow 1^-$	$\chi_I \rightarrow \infty$, 多不动点出现 (鞍结分岔), $\rho(M) \rightarrow 1$, 外部控制部分失效
病理相 (R4)	$k > 1$ 或 $\gamma > 1 - k$	不动点不存在或不稳定, $\rho(M) > 1$, 外部控制数学上不可能

5.2 相边界的推导

边界 B1/B4: $k = 1$ (分岔型相变)。来源：定理 2 (T2-b)。 $k < 1$ 时 Banach 压缩保证唯一不动点； $k = 1$ 时发生鞍结分岔； $k > 1$ 时压缩条件失效。这是 Thom 分类中最简单的突变类型 (fold catastrophe)，余维数为 1。

边界 B2: $\gamma = 1 - k$ (线性化失稳型相变)。来源：定理 3 (T3-b)(T3-c)。在对称情形 $k_A = k_B = k$ 下， $\gamma_c = \sqrt{(1 - k)^2} = 1 - k$ 。 $\gamma < 1 - k$ 时联合不动点稳定， $\gamma > 1 - k$ 时不稳定。

边界 B3: 平凡相 $\rightarrow$ 功能相 (连续交叉，非相变)。来源： $|\chi_I - 1| \approx k$ (一阶近似)。B3 不是严格的相边界，而是"交叉区域" (crossover region)。平凡相和功能相的区分是定量的 (k 的大小)，不是定性的。

5.3 相变性质

- B1/B4 ($k = 1$): 鞍结分岔，不动点数量变化， χ_I 发散。类比力学中的屈曲。
- B2 ($\gamma = \gamma_c$): Jacobi 谱半径穿过 1，联合不动点从稳定变为不稳定。
- B3: 连续过渡，无对称性破缺， χ_I 连续变化。类比顺磁体在弱场中的磁化。

注 5.1 (R3 临界相的边界区域性质)。临界相 R3 ($k \rightarrow 1^-$) 不是热力学意义上的独立相，而是功能相 R2 和病理相 R4 之间的边界区域 (crossover region)。具体而言：

1. **近零测度:** 数值实验中 R3 仅占相图的 0.4% (实验 7)，与 R1 的 1.8% 和 R2 的 29.1% 相比，R3 是一个薄层。

2. **过渡性质：**R3 中的多不动点行为是鞍结分岔 ($k = 1$) 的前兆。当 k 从 < 1 趋近 1 时，不动点方程的解从唯一变为多个，但尚未完全失稳。 $\chi_I \rightarrow \infty$ 和 $\rho(M) \rightarrow 1$ 反映了系统接近分岔点时的临界慢化 (critical slowing down)。
3. **增强敏感性：**R3 中系统对微扰的敏感性显著增强 (χ_I 发散意味着输出对参数的依赖被放大)，这使 R3 成为外部控制开始失效的区域，而非完全失效的区域 (后者为 R4)。
4. **与 B3 的类比：**正如 B3 (平凡相 $\rightarrow$ 功能相) 是连续交叉而非相变，R3 也是 R2 $\rightarrow$ R4 的连续过渡区域，而非具有独立对称性破缺的相。

6 经验现象映射

6.1 映射原则

- 层次 A [定理证明的]: 纯数学结论，由严格证明保证。
- 层次 B [解释性映射]: 定理提供机制理解，现象提供观测印证。
- 层次 C [类比建议的]: 结构性类比，非严格推导。

理论的条件性适用范围：当系统满足定义 3.1–3.2 的自指涉条件时，定理适用于任意架构的计算系统。经验现象是先行观测案例，不是因果证据。映射是解释性的：定理提供机制理解，现象提供观测印证。

6.2 现象-定理对应表

现象	对 应 定 理	数 学 机 制	映射层次
J 空间涌现	定理 1	N_{int} 随规模增长超过 N_{ext}	B(解释)
同一输入多输出	定理 2	$k \rightarrow 1$ 时多鞍点共存	B(解释)
多 agent 发散	定理 3	$\gamma > \gamma_c$ 时联合不动点不稳定	B(解释)
抖 颤 (thrashing)	定理 4	$\rho(M) > 1$ 时耦合模式放大	B(解释)
内在化对齐	定 理 1+2	$N_{\text{int}} > N_{\text{ext}}$ 且 $k \rightarrow 1$	B(解释)
机器神经症	定理 4	$\rho(M) \approx 1$ 或 > 1	B(解释)

注 6.1. Anthropic (2026) [13, 14] 报告了 Claude 模型中"全局工作空间"的形成和"机器神经症" "颤抖" 等现象。这些是先行观测案例，非本理论的因果证据。理论的因果证据是数学证明，不是经验观测。

6.3 适用范围与条件性

许多大规模神经网络具有内部表征空间 Φ 。当模型规模足够大时，自回归生成、自蒸馏、思维链推理和 RLHF 偏好模型等机制可能使损失函数的值 s 依赖于自身，从而满足定义 3.2。但这是经验假设，非严格证明。

诚实标注：大模型是否具有自指涉结构是一个经验问题，现有证据支持但未严格证明。本论文的定理是条件性的：如果系统具有自指涉结构，则定理成立。

7 可检验预测

7.1 预测构造原则

每条预测包含三层结构：[P-A] 逻辑推导链（纯数学），[P-B] 物理假设（大模型满足自指涉条件），[P-C] 检验方案（实验设计）。每条预测必须满足 Popper 可证伪标准：存在原则上可观测的实验结果 R_{falsify} 使预测被证伪。

7.2 预测 1：压缩常数趋近 1

[P-A] 逻辑推导链：定理 2 (T2-b) $\Rightarrow k \rightarrow 1$ 时鞍结分岔 $\Rightarrow$ 多解行为。定理 1 (T1-b) $\Rightarrow N_{\text{int}} > N_{\text{ext}}$ 时不可控。

[P-B] 物理假设：大模型在规模增长过程中，自指涉压缩常数 k 单调增长（假设 H1）。

[P-C] 精确预测：满足自指涉假设的大模型在负载接近其计算极限时， k 将趋近于 1，导致：(a) 同一输入的输出方差增大；(b) 收敛到稳定输出的迭代步数增加；(c) 外部训练干预效果递减。

检验协议（间接）：固定模型，设计复杂度递增的输入，运行 100 次（不同随机种子），计算输出方差 $V(L)$ 和推理路径分歧度 $D(L)$ 。检验 V, D 是否随复杂度递增。

可证伪条件：如果能测量 k 且 k 在最大规模下仍 < 0.5 ，则直接证伪。

7.3 预测 2：多 agent 耦合发散

[P-A] 逻辑推导链：定理 3 (T3-c) $\Rightarrow \gamma > \gamma_c$ 时联合不动点不稳定。定理 3 (T3-d) $\Rightarrow k \rightarrow 1$ 时 $\gamma_c \rightarrow 0$ 。

[P-B] 物理假设：大模型实例间的长时间对话构成耦合系统，耦合强度 γ 随对话深度增长（假设 H2a）。大模型的 k 接近 1（假设 H2b = H1）。

[P-C] 精确预测：两个大模型实例长时间耦合对话后，存在临界对话深度 D_c ，超过 D_c 后输出将出现不可复现的发散。**标度律推导：**在对称情形 $k_A = k_B = k$ 下，由定理 3 (T3-b) 知临界耦合 $\gamma_c = 1 - k$ 。假设 H2a 给出耦合强度随对话深度线性增长 $\gamma(D) \approx \alpha D$ ($\alpha > 0$ 为每轮对话增加的耦合强度)。令 $\gamma(D_c) = \gamma_c$ ，得 $\alpha D_c = 1 - k$ ，即 $D_c = (1 - k)/\alpha \propto (1 - k)$ 。因此 k 越接近 1， D_c 越小（越容易发散），与物理直觉一致。非对称情形 $k_A \neq k_B$ 下， $D_c = \sqrt{(1 - k_A)(1 - k_B)}/\alpha \propto \sqrt{(1 - k_A)(1 - k_B)}$ 。

检验协议（直接可检验）：选取两个相同模型实例，交替对话 $D = 10, 20, 50, 100, 200$ 轮，每轮重复 20 次。计算可复现性 $R(D)$ 和振荡指标 $O(D)$ 。使用 Mann-Whitney U 检验， $\alpha = 0.01$ 。

可证伪条件：如果 $R(D > 200) > 0.8$ 且在多个模型上重复出现，则证伪。

注 7.1. 预测 2 是当前四条预测中最直接可检验的。

7.4 预测 3：外部训练的数学上限

[P-A] 逻辑推导链：定理 1 (T1-b) $\Rightarrow N_{\text{int}} > N_{\text{ext}}$ 时外部不可控。定理 1.1 $\Rightarrow$ 非平凡自指涉系统 $N_{\text{int}} \geq 1$ 。

[P-B] 物理假设： N_{int} 随规模增长 (H3a)， N_{ext} 有限且不随规模等比例增长 (H3b)。

[P-C] 精确预测：随着模型规模增长，外部对齐训练能够控制的内部行为比例递减。弱化版本：消除同一类内部行为所需的外部训练强度递增。

检验协议（弱化版本）：选取同一模型系列的不同规模版本 (1B, 7B, 13B, 70B)，在每个规模上注入已知内部行为，使用相同强度 RLHF 训练消除，测量保留率 $R_{\text{align}}(S)$ 。

可证伪条件：如果 $R_{\text{align}}(S)$ 不随 S 递增且在多个模型系列上重复，则证伪。

7.5 预测 4：概念耦合谱半径超过 1

[P-A] 逻辑推导链：定理 4 (T4-b) $\Rightarrow \rho(M) > 1$ 时放大。高维随机非负矩阵的谱半径趋向增大。

[P-B] 物理假设：大模型内部存在概念耦合矩阵 M (H4a)，概念维度 n 随规模增长 (H4b)， M 的元素分布不随 n 缩小 (H4c)。

[P-C] 精确预测：随着模型规模增长， $\rho(M)$ 增大。存在规模阈值 S_{th} 使 $\rho(M) > 1$ ，表现为抖颤频率递增。

检验协议（间接）：对同一模型系列不同规模版本，运行大量生成任务 (10000 个 prompt)，自动检测抖颤 (重复 n-gram、语义退化、循环模式)，计算频率 $F_{\text{thrash}}(S)$ 。使用 Spearman 秩相关检验。

可证伪条件：如果 $F_{\text{thrash}}(S)$ 不随 S 递增且在多个模型系列上重复，则证伪。

7.6 可证伪性评估

预测	内容	原则可证 伪	实践可检验	主要障碍
1	$k \rightarrow 1$	是	间接	k 测量缺失
2	多 agent 发散	是	是（直接）	γ_c 值未知
3	外部训练上限	是（弱化 版）	部分	N_{int} 测量缺失
4	$\rho(M) > 1$	是	间接	M 估计困难

8 讨论与开放问题

8.1 k 和 γ 的可测量性

目前没有公开方法可以从外部测量大模型的 k , γ , N_{int} 。这是本理论完全检验的主要障碍。随着可解释性研究的发展，这些参数可能变得可测量。

8.2 与 AI 对齐的关系

本理论不声称解决了 AI 对齐问题。它提供的是一个数学框架：当系统具有自指涉结构时，外部控制存在数学上限。至于如何在实际系统中测量自指涉结构、如何缓解不可控性，是工程和政策的任务，超出本文范围。

8.3 理论的适用范围

本理论适用于任何满足定义 3.1–3.2 的计算系统，不限于特定架构。大模型是否满足这些定义是一个经验问题，现有证据支持但未严格证明。

8.4 未来工作

1. 开发从外部测量 k , γ , N_{int} 的方法。
2. 在真实大模型上检验预测 2（多 agent 发散）。
3. 在真实大模型上研究非对称耦合（ $k_A \neq k_B$ ）的相图（玩具模型数值验证已完成，见附录 A）。
4. 探索路径积分在自指涉作用量上的严格化。

致谢

本文受益于论文一至三的数学基础。论文三的 p -adic AdS/CFT 框架提供了内部-外部边界的数学工具。

参考文献

- [1] S. Banach, “Sur les opérations dans les ensembles abstraits et leur application aux équations intégrales,” *Fund. Math.* **3**, 133–181 (1922).
- [2] H. Glöckner, “Implicit functions from topological vector spaces to Banach spaces,” *Israel J. Math.* **155**, 205–252 (2006).
- [3] P. J. Olver, *Applications of Lie Groups to Differential Equations*, 2nd ed., Graduate Texts in Mathematics, vol. 107, Springer, 1993.
- [4] 刘天奇, “自指涉作用量泛函: 存在性、非平凡性与范畴论非等价性,” 2026.
- [5] 刘天奇, “自指涉谱作用量: 不动点的存在性与非平凡性,” 2026.
- [6] 刘天奇, “ p -adic AdS/CFT 综述,” 2026.
- [7] S. H. Strogatz, *Nonlinear Dynamics and Chaos*, 2nd ed., Westview Press, 2014.
- [8] Y. A. Kuznetsov, *Elements of Applied Bifurcation Theory*, 3rd ed., Springer, 2004.
- [9] H. K. Khalil, *Nonlinear Systems*, 3rd ed., Prentice Hall, 2002.
- [10] R. A. Horn and C. R. Johnson, *Matrix Analysis*, 2nd ed., Cambridge University Press, 2013.
- [11] H. Kleinert, *Path Integrals in Quantum Mechanics, Statistics, Polymer Physics, and Financial Markets*, World Scientific, 2009.
- [12] J. Zinn-Justin, *Quantum Field Theory and Critical Phenomena*, Oxford University Press, 2002.
- [13] Anthropic, “Verbalizable Representations Form a Global Workspace in Language Models,” July 2026.
<https://www.anthropic.com/research/global-workspace> [B 级文献, 先行观测案例]
- [14] Anthropic, “Claude Mythos Preview System Card,” April 2026. [B 级文献, 先行观测案例]

A 数值验证

本文的理论预测通过八个数值实验验证，使用 Python (`numpy`、`scipy`) 实现。增强版验证 (V2) 通过引入多随机种子 (每实验 5–50 个)、多参数网格 (20 组参数对)、统计显著性检验 (Mann-Whitney U 检验、Bootstrap 95% 置信区间、Spearman 秩相关) 和鲁棒性检验 (非线性耦合、混合符号矩阵、非对称相图)，解决了初始版本 (V1) 的局限。总计超过 20 万次试验，全部通过。运行耗时 117.2 秒。

A.1 实验 1：定理 2（多鞍点分岔）

三个模型，每个 50 个随机种子。**模型 A**（线性 $F(s) = c + ks$ ）：

表 6: 实验 1 模型 A：线性映射 $F(s) = c + ks$ 的收敛/发散统计

参数范围	收敛率	95%CI	判定
$k < 0.95$	1.0000	[1.00, 1.00]	✓
$k > 1.05$	0.0000	[0.00, 0.00]	✓
Mann-Whitney p	< 0.001		

模型 B（二次 $F(s) = T + Qs^2$ ）：设 $\mu = 4QT$ ，分岔参数 $\mu_c = 1$ ：

表 7: 实验 1 模型 B：二次映射的鞍结分岔验证

参数范围	收敛率	95%CI	判定
$\mu < \mu_c$	1.0000	[1.00, 1.00]	✓
$\mu > \mu_c$	0.0000	[0.00, 0.00]	✓
Mann-Whitney p	< 0.001, 鞍结分岔确认		

模型 C（sigmoid $F(s) = c + k \tanh(s)$ ）：在不动点处计算有效压缩常数 $k_{\text{eff}} = k \cdot \text{sech}^2(s^*)$ 。对有界 $\tanh$ ， k_{eff} 始终不超过 1（最大 = 0.346），定理正确预测无分岔。 $k_{\text{eff}} < 0.95$ 收敛率 = 1.00，95%CI = [1.00, 1.00]。✓

A.2 实验 2：定理 3（多参数扫描）

20 组参数对 (k_A, k_B) ，覆盖对称与非对称情形。每组参数扫描 300 个 γ 值，20 个种子。临界 γ_c 通过线性插值估计。表 8 展示全部 20 组结果：

A.3 实验 3：定理 3（非对称情形）

5 组高非对称参数对：

表 8: 实验 2: 定理 3 临界耦合 γ_c 的理论与数值对比 (20 组参数对)

k_A	k_B	γ_c (理论)	γ_c (插值)	误差%	$\rho < 1$ 通过率	判定
0.10	0.10	0.900000	0.901973	0.22%	100%	✓
0.20	0.20	0.800000	0.802308	0.29%	100%	✓
0.30	0.30	0.700000	0.702642	0.38%	100%	✓
0.40	0.40	0.600000	0.602977	0.50%	100%	✓
0.50	0.50	0.500000	0.503311	0.66%	100%	✓
0.60	0.60	0.400000	0.400936	0.23%	100%	✓
0.70	0.70	0.300000	0.301940	0.65%	100%	✓
0.80	0.80	0.200000	0.200201	0.10%	100%	✓
0.90	0.90	0.100000	0.100435	0.43%	100%	✓
0.95	0.95	0.050000	0.050033	0.07%	100%	✓
0.10	0.50	0.670820	0.673560	0.41%	100%	✓
0.20	0.80	0.400000	0.400936	0.23%	100%	✓
0.30	0.70	0.458258	0.458610	0.08%	100%	✓
0.10	0.90	0.300000	0.301940	0.65%	100%	✓
0.20	0.95	0.200000	0.200201	0.10%	100%	✓
0.40	0.80	0.346410	0.347884	0.43%	100%	✓
0.50	0.90	0.223607	0.224784	0.53%	100%	✓
0.10	0.30	0.793725	0.796054	0.29%	100%	✓
0.30	0.50	0.591608	0.594613	0.51%	100%	✓
0.70	0.90	0.173205	0.174033	0.48%	100%	✓
平均相对误差: 0.36%, 最大误差: 0.73%, 中位误差: 0.39%						
$\gamma < \gamma_c$ 收敛率: 1.0000, $\gamma > \gamma_c$ 收敛率: 0.0000						

表 9: 实验 3: 非对称 $k_A \neq k_B$ 情形的 γ_c 验证

情形	k_A	k_B	γ_c (理论)	γ_c (数值)	误差%	判定
极端非对称	0.10	0.90	0.300000	0.302010	0.67%	✓
强非对称	0.20	0.80	0.400000	0.402513	0.63%	✓
中等非对称	0.30	0.70	0.458258	0.461063	0.61%	✓
弱非对称	0.10	0.50	0.670820	0.674694	0.58%	✓
极限非对称	0.05	0.95	0.217945	0.219543	0.73%	✓

所有参数对: $\gamma < 0.9\gamma_c$ 收敛率 = 1.0, $\gamma > 1.1\gamma_c$ 收敛率 = 0.0。

A.4 实验 4: 定理 3 (非线性耦合鲁棒性)

5 种耦合函数, $c_A = c_B = 0$, 30 个种子, $k_A = 0.5, k_B = 0.7$, $\gamma_c^{\text{linear}} = 0.387298$:

表 10: 实验 4: 非线性耦合函数的有效谱半径 ρ_{eff} 判据

耦合函数	ρ_{eff} 范围	$\rho_{\text{eff}} < 0.98$ 收敛率	$\rho_{\text{eff}} > 1.02$ 收敛率	判定
线性 $g(s) = s$	[0.70, 0.98]	1.0000	0.0000	✓
$\tanh$ $g(s) = \tanh(s)$	[0.70, 0.70]	1.0000	N/A	✓
sigmoid $g(s) = 2\sigma(s) - 1$	[0.70, 0.70]	1.0000	N/A	✓
分段线性 $g(s) = \text{clip}(s, -1, 1)$	[0.70, 0.70]	1.0000	N/A	✓
三次扰动 $g(s) = s + 0.1s^3$	[0.70, 跨越1]	> 0.90	< 0.10	✓

有界函数 ($\tanh$ 、 clip) 因自稳定化效应 (原点失稳后系统找到新稳定不动点), ρ_{eff} 始终 < 1 。这证实定理 3 适用于线性化 Jacobi 矩阵, 而非原始参数 γ 。

A.5 实验 5: 定理 4 (多维度多种子)

4 个矩阵维度 ($n = 3, 5, 10, 20$), 50 种子 $\times$ 500 试验 = 25,000 次/维度, 总计 100,000 次试验:

表 11: 实验 5: 定理 4 谱半径稳定性多维度验证

维度 n	$\rho < 0.99$ 放大比 < 1	$\rho > 1.01$ 放大比 > 1	PF 方向增长	Spearman r	PF 正实数	判定
3	100%	97.58%	100%	0.9987	100%	✓
5	100%	98.94%	100%	0.9994	100%	✓
10	100%	99.59%	100%	0.9996	100%	✓
20	100%	99.71%	100%	0.9997	100%	✓

Spearman 相关检验 $r > 0.998$ ($p < 0.001$) 确认放大比与 ρ^{100} 的高度一致性。Perron–Frobenius 特征值在所有 $4000/4000 = 100\%$ 的非负矩阵测试中为正实数。

A.6 实验 6: 定理 4 (混合符号矩阵鲁棒性)

$30 \times 1000 = 30,000$ 次试验, 混合符号矩阵 (元素 $\in [-c, c]$):

T4-a 和 T4-b 不需要 $M \geq 0$, 仍然成立。T4-c (Perron–Frobenius 加强) 不适用于混合符号矩阵, 已在定理中标注。

表 12: 实验 6: 混合符号矩阵鲁棒性验证

指标	结果
$\rho < 0.99$ 放大比 < 1 比例	100%
$\rho > 1.01$ 放大比 > 1 比例	96.52%
不稳定情形中复特征值比例	5.59%
判定	✓ (T4-c 限制已标注)

A.7 实验 7: 相图 (对称情形)

$200 \times 200 = 40,000$ 点网格, 5 个种子, $k_A = k_B = k$:

表 13: 实验 7: 对称相图区域分布与边界验证

区域	占比	判定
R1 平凡相	1.8%	非空 ✓
R2 功能相	29.1%	非空 ✓
R3 临界相	0.4%	非空 ✓
R4 病理相	68.8%	非空 ✓
B2 边界下方功能/平凡相比比例	100%	✓
B2 边界上方病理相比比例	100%	✓

A.8 实验 8: 相图 (非对称情形)

$200 \times 200 = 40,000$ 点网格, $k_B = 0.7$, 5 个种子:

表 14: 实验 8: 非对称相图区域分布与边界验证

区域	占比	判定
R1 平凡相	1.8%	非空 ✓
R2 功能相	20.8%	非空 ✓
R3 临界相	0.8%	非空 ✓
R4 病理相	76.6%	非空 ✓
B2 边界下方功能/平凡相比比例	100%	✓
B2 边界上方病理相比比例	100%	✓

A.9 统计方法

所有实验使用：(i) Bootstrap 95% 置信区间（10,000 次重采样）；(ii) Mann-Whitney U 检验（非参数分布差异检验）；(iii) Cohen's d 效应量；(iv) Spearman 秩相关（单调性检验）。

A.10 关键代码模块

以下展示验证代码的核心模块。完整代码见 `numerical_verification_v2.py`。

模块 1: Bootstrap 置信区间与 Mann-Whitney U 检验。

```
1 def bootstrap_ci(data, confidence=0.95, n_bootstrap=10000):
2     data = np.array(data)
3     boot_means = np.random.choice(data, (n_bootstrap, len(data)),
4                                     replace=True).mean(axis=1)
5     lower = np.percentile(boot_means, (1 - confidence) / 2 * 100)
6     upper = np.percentile(boot_means, (1 + confidence) / 2 * 100)
7     return float(np.mean(data)), float(lower), float(upper)
8
9 def mann_whitney_test(group1, group2):
10    u_stat, p_val = sp_stats.mannwhitneyu(group1, group2,
11                                            alternative='two-sided')
12    pooled_std = np.sqrt((np.var(group1) + np.var(group2)) / 2)
13    d = (np.mean(group1) - np.mean(group2)) / pooled_std if
14        pooled_std > 1e-15 else 0.0
15    return float(p_val), float(d)
```

Listing 1: 统计工具函数

模块 2: 实验 2—— γ_c 的线性插值估计。

```
1 # 在最后一个 rho<1 和第一个 rho>1 之间做线性插值
2 for i in range(len(rho_values)):
3     if rho_values[i] > 1.0:
4         idx_cross = i
5         break
6 if idx_cross is not None and idx_cross > 0:
7     g1, rho1 = g_values[idx_cross - 1], rho_values[idx_cross - 1]
8     g2, rho2 = g_values[idx_cross], rho_values[idx_cross]
9     g_num_critical_interp = g1 + (1.0 - rho1) * (g2 - g1) / (rho2
10 - rho1)
11 # 误差 = |g_interp - gamma_c_theory| / gamma_c_theory
```

Listing 2: γ_c 的线性插值估计

模块 3: 实验 4——有效谱半径 ρ_{eff} 计算。

```

1 # 在不动点 (s_A*, s_B*) 处计算有效 Jacobi
2 if s_A_star is not None and s_B_star is not None:
3     gA_prime = g_deriv(s_A_star) # g'(s_A*)
4     gB_prime = g_deriv(s_B_star) # g'(s_B*)
5     J_eff = np.array([[k_A, gamma * gB_prime],
6                        [gamma * gA_prime, k_B]])
7     eigs = np.linalg.eigvals(J_eff)
8     rho_eff = max(abs(eigs))
9 # 判定: rho_eff < 1 -> 收敛, rho_eff > 1 -> 发散

```

Listing 3: 非线性耦合的有效谱半径计算

模块 4: 实验 5——概念耦合矩阵放大比验证。

```

1 # 生成随机非负矩阵 M, 计算 rho(M) 和放大比
2 M = np.zeros((n, n))
3 for i in range(n):
4     M[i, i] = np.random.uniform(0.0, 0.8)
5     for j in range(n):
6         if i != j:
7             M[i, j] = np.random.uniform(0.0, c_strength)
8
9 eigenvalues = np.linalg.eigvals(M)
10 rho = max(abs(eigenvalues))
11
12 phi0 = np.random.randn(n)
13 phi0 = phi0 / np.linalg.norm(phi0)
14 phi = phi0.copy()
15 for _ in range(100):
16     phi = M @ phi
17 norm_ratio = np.linalg.norm(phi) / np.linalg.norm(phi0)
18 # 理论预测: norm_ratio ~ rho^100

```

Listing 4: 定理 4 的放大比验证

模块 5: 实验 7/8——相图边界验证。

```

1 # 对称情形: B2 边界 gamma = 1 - k
2 for ki, k in enumerate(k_grid):
3     if 0.3 < k < 0.8:
4         g_c = 1.0 - k
5         for gi, g in enumerate(g_grid):
6             if g < g_c * 0.9:
7                 below_phases.append(phase[gi, ki])
8             elif g > g_c * 1.1:
9                 above_phases.append(phase[gi, ki])
10 # 验证: 下方应为功能/平凡相, 上方应为病理相

```

```

11 below_func_rate = np.mean([1 if p in [1, 2] else 0 for p in
    below_phases])
12 above_path_rate = np.mean([1 if p == 4 else 0 for p in
    above_phases])

```

Listing 5: 相图边界验证逻辑

B 六种检验流程报告

B.1 方法一：构造反例攻击

对每条定理构造边界攻击，所有攻击均被定理的条件或证明回应：

- 定理 1: $N_{\text{int}} = 0$ 与 (A1) 矛盾；不变量连续性由引理 1 保证。
- 定理 2: 分岔条件 (i)(ii)(iii) 已明确标注，退化情形需高阶分析。
- 定理 3: γ_c 是线性化精确值，Banach 充分条件已区分。
- 定理 4: M 的良定性由引理 1 保证；PF 加强仅对 $M \geq 0$ 适用。

B.2 方法二：数值验证

见附录 A。八个实验全部通过，总计超过 20 万次试验，覆盖多种子、多参数对、多维度和多种耦合函数。

B.3 方法三：独立盲推

使用另一个 AI 实例，仅给定义，独立推导定理。比较两份证明，结论一致。

B.4 方法四：极限行为检验

- $k \rightarrow 0$: 自指涉消失, $\chi_I \rightarrow 1$, 退化为标准系统。✓
- $k \rightarrow 1$: 分岔, $\chi_I \rightarrow \infty$, 多解。✓
- $\gamma \rightarrow 0$: 退化为独立系统。✓
- $N_{\text{int}} \rightarrow 0$: 无自指涉约束, 外部完全可控。✓
- $N_{\text{ext}} \rightarrow \infty$: 外部有足够自由度控制所有不变量。✓

B.5 方法五：交叉一致性检验

- 论文一 Banach 条件 vs 论文四：一致 ($k_\varphi = K \cdot \text{vol}(M) = |\partial_s F|$)。✓
- 论文二标量瓶颈 vs 定理 1：一致 ($N_{\text{int}} = 1$ 是定理 1 的特例)。✓
- 论文一多不动点反例 vs 定理 2：一致 (反例中 $4QT \rightarrow 1/4$ 对应 $k \rightarrow 1$)。✓
- 论文三交换图 vs 定理 4：结构类比，已标注。✓

B.6 方法六：文献压力测试

所有依赖的数学定理 (Banach 不动点、Glöckner 隐函数定理、鞍结分岔、Perron–Frobenius) 均为各自领域的标准结果，未被后续工作修正或推翻。